

MODELADO PREDICTIVO DEL COMPORTAMIENTO ASISTENCIAL

Atención Médica Ambulatoria
(2022–2025)


 Proyecto de Ciencia de Datos
Análisis Exploratorio y Predictivo

Autor: Diego Silvera
Setiembre 2025



Rodmap del Proyecto

Modelado de eficiencia y comportamiento asistencial en la atención médica ambulatoria pública un análisis exploratorio descriptivo multianua



CONTEXTO Y JUSTIFICACIÓN



El ausentismo médico ambulatorio afecta la eficiencia del sistema de salud pública, generando:

1

Subutilización de recursos.

2

Reprogramaciones innecesarias

3

Aumento en los tiempos de espera.

Este proyecto analiza datos multianuales (2022–2025) para identificar patrones y anticipar la asistencia.

HIPÓTESIS

Se nota una baja constante en la tasa de consultas asistidas frente a las ofertadas y asignadas, con variaciones notables entre unidades y especialidades.

Esto podría deberse a problemas en la gestión de agendas, distribución de servicios o factores socioeconómicos externos no considerados.



OBJETIVOS



GENERAL

Modelar el comportamiento asistencial para anticipar ausencias y optimizar recursos.



ESPECIFICOS

Analizar datos multianuales (2022–2025).

- Balancear clases de asistencia.
- Explorar reducción dimensional (PCA).
- Comparar modelos predictivos.

METODOLOGÍA

01

ADQUISICIÓN DE DATOS.

02

LIMPIEZA Y PREPARACIÓN.

03

ANÁLISIS EXPLORATORIO (EDA).

04

BALANCEO Y PCA.


05

MODELADO Y EVALUACIÓN.




Análisis Exploratorio

- Variaciones estacionales claras.
- Especialidades con mayor inasistencia.
- Picos de asignación en ciertos meses.



- La tasa de asistencia se mantuvo estable en torno al 69–71%.
- Se observan variaciones estacionales, con picos en algunos meses.
- Diferencias relevantes entre especialidades y unidades asistenciales



BALANCEO DE CLASES

Problema:



Desbalance significativo en la variable objetivo (asistió/no asistió).

Solución:

Aplicación de RandomOverSampler para equilibrar las clases en el conjunto de entrenamiento.

Impacto:


Mejora en la capacidad predictiva de la clase minoritaria.




PCA

Análisis de Componentes Principales

- Se evaluó la reducción de dimensionalidad para optimizar el tiempo de entrenamiento y los recursos computacionales. El método del codo indicó que a partir del componente 15 la ganancia de varianza era mínima.
- Se concluyó que no aportaba mejoras significativas en la mayoría de modelos, salvo en el Árbol de Decisión, donde las métricas se mantuvieron estables con y sin PCA..




COMPARACIÓN FINAL DE MODELOS




Árbol de
Decisión

Accuracy: 0.90
Precision: 0.90
Recall: 1.0
F1-Score: 0.95




Regresión
Logística

Accuracy: 0.93
Precision: 0.93
Recall: 1.0
F1-Score: 0.96



Random
Forest

Accuracy: 0.93
Precision: 0.93
Recall: 1.0
F1-Score: 0.96




XGBOOST ING

Accuracy: 0.93
Precision: 0.93
Recall: 1.0
F1-Score: 0.96

COMPARACIÓN DE MODELOS SUPERVIDADOS

Aunque las métricas fueron cercanas, Regresión Logística mostró un rendimiento más estable en Recall y F1-Score, superando ligeramente a Random Forest.



Segmentación de Unidades y Especialidades con K-Means


- Se aplicó K-Means para segmentar unidades/especialidades en base a indicadores de gestión.
- Se evaluaron distintos k con Silhouette Score para elegir el número óptimo de clusters.
- El modelo identificó perfiles de gestión diferenciados:
- Ej.: clúster con alta inasistencia y % libres elevado → alerta de ineficiencia.
- Los centroides permiten interpretar cada perfil y priorizar intervenciones.

Centroides (escala original de indicadores):

	tasa_asistencia
0	0.670660
1	0.535187
2	0.935885
3	0.781015



Clusters (K-Means, k=4) - 1D



Conclusiones generales

- No hubo caída sostenida: estabilidad 2022–2024 y leve recuperación en 2025.
- Sí hubo diferencias relevantes por unidad y especialidad.
- Los modelos confirmaron que es posible predecir inasistencia con alta precisión.

Evaluación de objetivos

- Dataset limpio y consolidado ✓.
- Indicadores de gestión calculados ✓.
- Tendencias y desbalances detectados ✓.
- Modelos predictivos explorados y optimizados ✓.



Optimización del modelo

- Probamos distintas validaciones (LOOCV, Stratified K-Fold).
- Ajustamos hiperparámetros con Grid y Random Search.
- Usamos ensembles (RF y XGBoost).
- XGBoost fue el mejor modelo (F1 = 0.959).


Valor agregado del pipeline

- Datos: base multianual confiable.
- EDA: evidencia clara para la gestión.
- Modelado: predicciones robustas y precisas.
- Aplicación:
 - Anticipar ausencias en agenda.
 - Recordatorios automáticos.
 - Redistribución de cupos y recursos.

REPOSITORIO Y CRÉDITOS



Proyecto: Modelado Predictivo del Comportamiento Asistencial



Tutores:

Prof: Germán Rodríguez

Prof Adj. Yamil Salomón



Autor: Diego Silvera



Repositorio con código, datos y análisis disponible en:

[git@github.com:Diego-Silvera/An-lisisde-eficiencia-en-la-asignaci-n-y-asistencia-a-consultas-m-dicas-entre-2022-y-2025.git](https://github.com/Diego-Silvera/An-lisisde-eficiencia-en-la-asignaci-n-y-asistencia-a-consultas-m-dicas-entre-2022-y-2025.git)



MUCHAS GRACIAS

